



面向开放域问答的 工具调用智能体设计与优化

本科毕业设计开题报告

李明柠 2023311423

指导教师：陈科海

2026 年 4 月





目录

1 背景与意义

► 背景与意义

► 研究现状

► 研究方案

► 关键优化

► 实验与计划



汇报主线：从问题到验证

1 背景与意义

为什么做

开放域问答经常涉及最新事实、长尾实体和多跳关系，单靠模型参数记忆难以稳定回答。

怎么解决

围绕“何时搜、搜什么、怎么用”，设计检索触发、查询改写、证据压缩和预算控制模块。

问题在哪

现有检索增强方法常见问题是触发不稳、查询不准、网页证据噪声大和调用成本不可控。

怎么验证

通过公开数据集与自建问题集，对准确性、检索有效性、调用效率和稳定性进行对比评测。

答辩陈述重点：本课题解决的是外部信息获取链路不可控的问题。



课题背景：开放域问答需要外部知识

1 背景与意义

- 开放域问答面对未知主题、跨领域事实和多跳关系，单靠参数记忆难以保证准确。
- 大语言模型具备较强的问题理解和生成能力，但仍受制于知识截止、长尾事实缺失和推理链误差传播。
- 检索增强生成和工具调用智能体为模型接入搜索、网页阅读和证据整理能力提供了路径。

核心矛盾

模型会推理，
但不一定知道最新事实；

网页有答案，
但噪声、冗余和成本很高。



研究意义与实施意义

1 背景与意义

研究意义

- **何时搜**：判断时间敏感、长尾事实和多跳关系，避免漏搜或过度检索。
- **搜什么**：将复杂问题拆成实体、关系和约束明确的可执行查询。
- **怎么用**：从网页长文本中抽取结构化证据，增强答案可追溯性。

实施意义

- **真实问答**：覆盖最新事实、长尾实体和跨网页信息，减少参数记忆缺口。
- **系统落地**：串联搜索、阅读、证据整理和答案生成，并记录日志与预算。
- **可信生成**：让答案建立在短证据和来源 URL 上，降低无证据断言。

核心价值：把智能体检索从“接入工具”推进到“控制调用链路”。



目录

2 研究现状

- ▶ 背景与意义
- ▶ 研究现状
- ▶ 研究方案
- ▶ 关键优化
- ▶ 实验与计划



相关研究脉络

2 研究现状

方向	代表思路	启示与不足
检索增强生成	RAG 在生成前引入外部文档，缓解模型知识不足	典型流程多为一次性检索，难覆盖多跳中间事实
智能体工具调用	WebGPT、ReAct、Self-Ask、IRCoT 等将搜索/阅读嵌入推理过程	能动态补充信息，但容易出现重复搜索、查询过宽和无关网页干扰
网页检索增强推理	Search-R1、Search-o1、WebThinker 等强调多轮搜索、网页阅读和证据整合	真实网页存在长文本噪声、正文抽取失败和调用成本控制问题



现有问题分析

2 研究现状

触发不稳

简单问题过度检索，复杂事实又可能漏搜，造成成本浪费或幻觉回答。

查询不准

原始长问题直接搜索时，实体、关系和约束不清，影响关键网页召回。

证据噪声

网页正文长且杂，若直接注入上下文，会放大无关信息和 token 消耗。

本课题聚焦：检索触发、查询改写、网页证据压缩与调用预算控制。



方法解决的问题

2 研究现状

问题	方法设计	解决效果
触发不稳	规则信号 + 模型自评，判断时间敏感、长尾事实、多跳关系和证据缺口	降低简单问题过度检索，减少复杂问题漏检导致的幻觉回答
查询不准	将复杂问题拆成带实体、关系和约束的子查询，并记录检索目的	提升关键网页召回质量，避免直接搜索长自然语言问题
证据噪声	网页正文抽取后进行证据压缩，输出事实、URL、子目标和相关性评分	减少长网页注入造成的噪声和 token 成本，增强答案可追溯性
调用膨胀	查询去重、URL 去重、证据哈希、最大轮数和 token 预算控制	控制搜索次数、读取网页数、响应延迟和 API 成本



目录

3 研究方案

- ▶ 背景与意义
- ▶ 研究现状
- ▶ 研究方案
- ▶ 关键优化
- ▶ 实验与计划



主要研究内容


3 研究方案

1. **构建原型系统**：实现开放域问答检索工具调用智能体，支持问题输入、多轮搜索、网页读取、证据整理和答案生成。
2. **设计多轮检索流程**：形成“推理-搜索-阅读-整理-继续推理”的循环，并记录查询、URL、网页片段和使用状态。
3. **实现证据压缩模块**：将网页正文转化为短而可验证的结构化证据，包括事实、来源、关联子目标和相关性判断。
4. **开展链路优化评测**：比较直接回答、单次 RAG、多轮检索智能体和改进系统在准确性、效率与稳定性上的差异。



系统总体架构

3 研究方案



系统以大语言模型为推理核心，围绕网页文本检索工具形成可记录、可控制、可评测的调用链路。



模块设计


3 研究方案

模块	主要功能	实现方式
问题分析模块	识别问题类型、实体、时间敏感性和多跳需求	大模型 API + 提示词约束
检索控制模块	决定是否搜索、生成查询、控制最大轮数和调用预算	规则信号 + 模型自评
搜索工具模块	调用搜索引擎并返回候选结果	开放搜索接口，预留替代接口
网页抽取模块	读取 URL、清洗 HTML、提取正文和标题	readability / trafilatura / Jina Reader 类工具
证据整理模块	抽取相关事实、去重、排序、记录来源	证据压缩提示词 + 规则整理
答案生成模块	综合证据生成最终答案并输出依据	大模型 API + 结构化证据输入



技术路线

3 研究方案



证据不足时进入下一轮

最大轮数

最大 URL 数

token 预算

响应时间与费用记录

基本流程覆盖查询生成、外部检索、网页读取、证据整理与答案生成，优化环节贯穿整个调用链路。



目录

4 关键优化

- ▶ 背景与意义
- ▶ 研究现状
- ▶ 研究方案
- ▶ 关键优化
- ▶ 实验与计划



优化一：自适应检索触发

4 关键优化

触发信号

- 时间表达或最新事实
- 长尾实体、专业事实
- 多实体比较或多跳关系
- 模型自评“缺少证据”

控制目标

- 简单问题尽量直接回答
- 复杂事实主动补充外部证据
- 通过最大轮数、URL 数和 token 预算限制过度调用



优化二：查询生成与改写

4 关键优化

原始问题

“甲和乙是否出生在同一城市？”

直接搜索的问题

查询过长、意图混合，容易召回泛化页面或问答噪声。

改写策略

- 明确每个查询的检索目的
- 拆分为关键实体 + 关系词
- 保留必要时间、地点和限定条件

甲 birth place

乙 birth place



优化三：网页证据压缩

4 关键优化

输入

- 当前问题与子目标
- 搜索查询与网页 URL
- 网页标题、摘要、正文片段
- 已有推理状态

输出结构


fact	可验证事实
url	来源链接
goal	支持的子问题
time	证据时间
score	相关性评分

目标：让主模型接收短证据，而不是整篇网页。



优化四：冗余调用与预算控制

4 关键优化



平均搜索次数

平均读取网页数

token 消耗

响应时间

API 成本



目录

5 实验与计划

- ▶ 背景与意义
- ▶ 研究现状
- ▶ 研究方案
- ▶ 关键优化
- ▶ 实验与计划



实验方案

5 实验与计划

数据来源

- HotpotQA: 多跳实体关系推理
- MuSiQue / 2WikiMultiHopQA: 组合问答
- GAIA: 真实信息获取与工具使用
- WebWalkerQA: 网页检索与多步定位
- 自建网页文本问题集

对比方法

- Direct LLM: 不检索直接回答
- Standard RAG: 原始问题单次检索
- Agentic Search: 多轮搜索, 无独立证据压缩
- Ours: 加入触发、改写、压缩和预算控制



评价指标

5 实验与计划

指标类别	具体度量
答案准确性	Exact Match、F1；自建问题采用人工核验或证据一致性评分
检索有效性	支持答案网页命中率、有效证据占比、证据相关性
工具调用效率	平均搜索次数、平均读取网页数、响应时间、token 消耗、API 费用
推理稳定性	同一问题多次运行的答案一致性、证据一致性和失败率
可解释性	最终答案是否能对应明确证据来源，是否存在无证据断言



预期成果与风险应对

5 实验与计划

预期成果

- 可运行的开放域问答工具调用智能体原型
- 可复现实验脚本与评测数据子集
- 至少一种关键优化方法及消融实验
- 实验结果表、案例分析和毕业论文

风险应对

- 搜索接口：缓存、重试和备用接口
- 网页噪声：长度、重复度、关键词覆盖过滤
- 触发不稳：规则信号 + 模型自评 + 预算限制
- 评价主观：公开指标 + 人工核验表



总结

5 实验与计划

本课题面向开放域问答中的外部知识获取需求，
设计一个可运行、可控制、可评测的
网页检索工具调用智能体。

系统实现

多轮检索与网页阅读流程

链路优化

触发、查询、证据、预算

实验评测

准确性、效率、稳定性



Q&A

Thank you for listening!
Your feedback will be highly appreciated!