

开题答辩逐页讲稿

主题：面向开放域问答的工具调用智能体设计与优化

使用方式：每页先讲“这一页的目的”，再讲图或表中的核心内容，最后用一句话过渡到下一页。整体主线是：

开放域问答需要外部知识 → 网页检索工具调用存在链路不可控问题 → 本课题围绕“什么时候搜、搜什么、搜多少”做系统优化 → 通过原型系统和实验验证效果。

第 0 页：封面

这一页简要介绍题目、姓名、学号和指导教师。

可以说：

各位老师好，我的开题题目是《面向开放域问答的工具调用智能体设计与优化》。本课题主要关注开放域问答中大模型如何调用网页检索工具，并围绕检索触发、查询生成和调用预算控制进行系统优化。下面我将从研究背景、相关工作、研究方案、关键优化和实验计划五个方面进行汇报。

过渡：

首先介绍课题背景，为什么开放域问答需要外部知识。

第 1 页：课题背景：开放域问答需要外部知识

这一页讲“为什么不能只靠大模型参数记忆”。

可以说：

开放域问答和普通问答不同，它的问题范围不固定，可能涉及不同领域、最新信息、冷门实体和多跳关系。因此，大模型只依赖训练阶段形成的参数记忆是不够的。

展开三点：

- 第一，知识有时效性。近期新闻、论文、产品信息等内容会变化，模型内部知识可能过时。
- 第二，长尾事实容易缺失。冷门人物、小众机构、具体网页信息在训练语料中覆盖不足，模型容易答错。
- 第三，多跳问题需要中间事实。系统需要先查到若干中间事实，再综合推理；如果中间事实错了，最终答案也会错。

收束：

所以开放域问答系统需要引入外部知识，尤其是网页检索和网页内容读取。我的课题就是研究大模型智能体如何调用网页检索工具，并把检索到的信息整理成可用于回答的证据。简单说，就是让模型不是凭记忆硬答，而是在需要的时候会查网页，并且能把查到的信息用好。

过渡：

基于这个背景，下面进一步说明本课题的研究意义和实施意义。

第 2 页：研究意义与实施意义

这一页分清两个概念：研究意义偏方法层面，实施意义偏系统落地层面。

研究意义可以说：

当前很多系统已经可以接入搜索工具，但真正影响效果的是工具调用链路是否可控，也就是：什么时候搜、搜什么、搜多少。如果检索触发不稳定，就会出现简单问题过度检索、复杂问题漏检；如果查询生成质量不高，就很难召回关键网页；如果没有预算控制，多轮搜索会带来较高延迟和成本。因此，本课题研究的是网页检索工具调用链路优化问题。

实施意义可以说：

实施意义主要体现在系统层面。本课题会实现一个面向开放域问答的网页检索智能体原型，跑通查询生成、外部检索、网页内容读取、证据整理和答案生成流程。系统不仅能调用网页获取外部知识，还能记录来源、整理短证据，并从准确性、检索有效性、调用次数和响应时间等指标上进行评测。

总结句：

所以，研究意义是分析和优化网页检索工具调用机制；实施意义是做出一个可运行、可评测的开放域问答智能体原型。

过渡：

接下来介绍相关研究脉络，看现有方法发展到什么阶段，以及还存在哪些不足。

第 3 页：相关研究脉络

这一页不是逐篇论文介绍，而是讲研究方向的演进。

可以说：

和本课题相关的研究大致可以分为三类。

第一类：

第一类是检索增强生成，也就是 RAG。它的核心思路是在模型生成前引入外部文档，用来缓解大模型知识不足的问题。RAG 对开放域问答很重要，但典型流程通常是对原始问题做一次性检索，然后把 Top-K 文档交给模型。因此在多跳问题中，它往往难以覆盖后续推理过程中才出现的中间事实。

第二类：

第二类是智能体工具调用，例如 WebGPT、ReAct、Self-Ask 和 IRCoT。这类方法把搜索、阅读等动作嵌入推理过程，让模型可以在解题过程中动态补充外部信息。相比固定 RAG，它更灵活，但也带来新问题，比如什么时候搜索不稳定、查询可能过宽、重复搜索较多，以及网页内容可能干扰推理。

第三类：

第三类是网页检索增强推理，比如 Search-R1、Search-o1、WebThinker 等。这类工作进一步强调多轮搜索、网页阅读和证据整合，和我的课题关系更近。它们说明网页工具调用对复杂信息获取任务有价值，但真实网页环境中仍然存在长文本噪声、正文抽取失败以及多轮调用成本难以控制的问题。

收束：

所以我的课题不是重新提出一个大模型，而是面向网页检索工具调用这个链路，做一个本科阶段可实现、可评测的系统优化。

过渡：

基于这些相关研究，我将现有问题归纳为三个方面。

第 4 页：现有问题分析

这一页讲本课题要解决的主要问题。核心是“什么时候搜、搜什么、搜多少”。

可以说：

基于上面的研究脉络，我把当前开放域问答中的网页检索工具调用问题归纳为三个方面。

问题一：检索触发不稳定。

如果完全让模型自由决定是否调用工具，简单问题可能也会触发搜索，造成过度检索；而真正需要外部证据的问题又可能没有搜索，导致答案缺乏依据甚至出现幻觉。

问题二：查询质量影响大。

复杂开放域问题通常不是一个搜索词就能解决的，它可能需要拆成多个中间事实。如果直接把用户的原始长问题丢给搜索引擎，查询可能过长、过泛，导致关键网页召回不足。

问题三：调用成本需要控制。

多轮搜索、网页读取和证据整理都会消耗 token 和时间。如果没有预算控制，系统可能为了一个问题反复搜索、重复读取网页，导致成本和延迟上升。

总结：

所以后面的系统设计主要围绕三个问题展开：什么时候搜、搜什么、搜多少。

过渡：

针对这几个问题，下一页说明我的方法分别怎么处理。

第 5 页：方法解决的问题

这一页是“问题—方法—效果”的对应关系，适合重点讲清楚你的方法到底解决什么。

可以说：

针对前面归纳的几个问题，我的方法不是只加一个搜索接口，而是对网页检索工具调用链路做模块化控制。

第一行：触发不稳。

对于检索触发不稳，我采用规则信号和模型自评结合的方式，根据问题是否涉及时间敏感信息、长尾事实、多跳关系和证据缺口来判断是否检索。这样可以降低简单问题过度检索，也减少复杂问题漏检导致的幻觉回答。

第二行：查询不准。

对于查询不准，我会把复杂问题拆成带实体、关系和约束的子查询，并记录每个查询的检索目的。这样比直接搜索原始长自然语言问题更容易召回关键网页。

第三行：证据噪声。

对于网页证据噪声，我会先做网页正文抽取，再进行证据整理，只保留和当前问题相关的短证据片段，包括事实、来源 URL、对应子目标和相关性评分。这样主模型不用直接阅读整篇长网页。

第四行：调用膨胀。

对于调用膨胀，我会做查询去重、URL 去重、证据去重，并设置最大搜索轮数、最大读取网页数和 token 预算，用来控制搜索次数、网页读取数、响应延迟和 API 成本。

总结句：

所以我解决的不是某一个单点模型能力问题，而是开放域问答中网页信息获取链路不可控的问题。

过渡：

下面介绍这些方法在课题中具体对应哪些研究内容。

第 6 页：主要研究内容

这一页讲“我要做哪些工作”，不用展开过细。

可以说：

本课题的研究内容分为四部分。

第一，构建原型系统。

系统面向开放域问答，支持用户输入问题后，自动完成多轮搜索、网页读取、证据整理和答案生成。也就是说，先把题目要求中的基本流程跑通。

第二，设计多轮检索流程。

系统不是只搜索一次，而是形成“推理、搜索、阅读、整理、继续推理”的循环。每一轮都会记录 query、URL、网页片段和使用状态，这样后续可以分析工具到底怎么被调用。

第三，实现网页证据整理，也就是这里的证据压缩模块。

它不直接把整篇网页塞给模型，而是把网页正文整理成短而可验证的证据片段，包括事实内容、来源 URL、对应子问题和相关性判断。这个模块主要是为答案生成提供干净的证据输入。

第四，开展链路优化评测。

我会比较直接回答、单次 RAG、多轮检索智能体和改进系统，观察它们在准确性、工具调用效率和稳定性上的差异。

收束：

所以这部分对应的是：先实现完整流程，再围绕检索触发、查询生成和调用预算控制做优化评测。

过渡：

下面说明这些内容在系统中如何组织。

第 7 页：系统总体架构

这一页看图讲，按模块顺序说明。

可以说：

这一页是系统总体架构。系统以大语言模型作为推理核心，外部工具主要聚焦网页文本检索，包括搜索接口和网页正文抽取。

按流程讲：

用户输入问题后，首先进入问题分析和检索控制模块。系统判断这个问题是否需要外部网页证据，如果需要，就生成搜索 query。

接着搜索工具模块调用开放搜索接口，返回候选网页。网页抽取模块负责读取 URL，清洗网页正文，去掉导航栏、广告、重复文本等噪声。

然后证据整理模块会从网页正文中抽取和当前问题相关的短证据片段，并记录来源 URL 和相关性。最后答案生成模块基于整理后的证据生成最终回答。

强调系统特点：

这套架构的重点不是单纯接一个搜索工具，而是让整个工具调用链路可记录、可控制、可评测。比如每一轮搜索了什么 query、读了哪些网页、用了哪些证据、消耗多少 token，都会被记录下来，用于后续实验分析。

过渡：

架构图说明系统有哪些模块，下一页技术路线说明这些模块在一次问答任务中如何协同运行。

第 8 页：技术路线

这一页讲“系统运行时按什么流程走”。

可以说：

这一页是技术路线，和前面的系统架构相比，它更强调运行时的流程。

按图讲：

首先是问题分析和检索触发。系统判断问题是否需要外部知识，如果不需要就直接回答；如果需要，就进入检索流程。

第二步是查询生成与改写。系统根据问题中的实体、关系和约束生成可执行的搜索 query。对于多跳问题，会拆成多个子查询。

第三步是外部检索与候选筛选。系统调用搜索接口获取候选网页，并根据 URL 去重、关键词覆盖率、页面可访问性等规则筛选网页。

第四步是网页读取和正文抽取。系统读取网页内容，并去除无关网页结构，保留正文片段。

第五步是证据整理和答案生成。系统把长网页整理成短证据，再交给模型综合回答。

讲下面的小标签：

下面这些标签是预算控制和日志记录。证据不足时，系统可以进入下一轮检索；但同时会设置最大轮数、最大 URL 数和 token 预算，避免无限搜索。系统还会记录响应时间和费用，用于评估调用效率。

收束：

所以这条技术路线覆盖了题目要求的查询生成、外部检索、网页内容读取、证据整理和答案生成，同时把检索触发、查询改写和预算控制作为优化环节贯穿整个调用链路。

过渡：

下面介绍几个关键优化模块。

第 9 页：优化一：自适应检索触发

这一页讲“什么时候搜”。

可以说：

第一个优化是自适应检索触发，解决的是“什么时候搜”的问题。

左侧触发信号：

系统会关注几类信号：问题是否包含时间表达或最新事实，是否涉及长尾实体和专业事实，是否需要多实体比较或多跳关系，以及模型自评时是否判断缺少证据。

右侧控制目标：

控制目标是：简单问题尽量直接回答，避免无意义搜索；复杂事实问题主动补充外部证据，降低幻觉风险；同时通过最大轮数、URL 数和 token 预算限制过度调用。

收束：

这一模块的目标不是让系统所有问题都搜索，而是让检索行为更有选择性。

过渡：

判断需要搜索之后，下一步就是生成什么查询。

第 10 页：优化二：查询生成与改写

这一页讲“搜什么”。

可以说：

第二个优化是查询生成与改写，解决的是“搜什么”的问题。

左侧例子：

比如“甲和乙是否出生在同一城市”这个问题，如果直接搜索原始长句，搜索词会比较泛，里面混合了两个实体和比较关系，不一定能召回关键网页。

右侧策略：

因此系统会先明确每个查询的检索目的，再把复杂问题拆成关键实体加关系词的子查询，例如“甲 birth place”和“乙 birth place”。必要时还会保留时间、地点等限定条件。

收束：

这样做的目标是提高关键网页召回质量，避免直接搜索长自然语言问题带来的噪声。

过渡：

搜到网页后，还需要解决网页太长、噪声太多的问题。

第 11 页：优化三：网页证据压缩

这一页讲“网页怎么用”，但注意口头上把它定位成支撑模块，不是主创新。

可以说：

第三个模块是网页证据整理，也就是这里的网页证据压缩。它主要解决网页正文太长、噪声太多的问题，是答案生成的支撑模块。

输入：

输入包括当前问题和子目标、搜索查询和网页 URL、网页标题摘要正文片段，以及已有推理状态。

输出：

输出是结构化短证据，包括可验证事实、来源链接、支持的子问题、证据时间和相关性评分。

重点解释：

系统不会直接把整篇网页交给主模型，而是围绕当前查询抽取短证据片段。这样可以减少长网页注入造成的噪声和 token 成本，也让最终答案更容易追溯到来源。

收束：

所以这个模块的作用是让主模型基于短证据回答，而不是基于完整网页正文或参数记忆硬答。

过渡：

最后一个优化模块是控制冗余调用和预算。

第 12 页：优化四：冗余调用与预算控制

这一页讲“搜多少”和“什么时候停”。

可以说：

这一页是冗余调用与预算控制模块，主要解决工具调用成本和响应延迟问题。

按图讲：

系统首先对模型生成的 query 做去重，避免重复搜索相似问题。然后对搜索结果 URL 去重，避免重复读取同一网页。

接着对抽取到的证据片段进行去重，判断当前搜索是否带来了新的有效证据。如果连续搜索没有新增证据，或者证据已经足够支持答案，系统就提前停止。

同时系统设置最大搜索轮数、最大读取网页数和 token 预算，用来控制整体成本。

评价指标：

最后我会用平均搜索次数、平均读取网页数、token 消耗、响应时间和 API 成本来评估这个模块的效果。

建议口头替换：

PPT 里“证据哈希”可以讲成“证据去重”，更好理解。

过渡：

下面介绍实验方案，说明如何验证这些优化是否有效。

第 13 页：实验方案

这一页讲“用什么数据、和谁比”。

可以说：

实验方案分为数据来源和对比方法两部分。

数据来源：

数据方面，我计划选择公开数据集的小规模子集，包括 HotpotQA，用于测试多跳实体关系推理；MuSiQue 或 2WikiMultiHopQA，用于测试组合问答；GAIA，用于测试真实信息获取和工具使用；WebWalkerQA，用于测试网页检索和多步定位；此外还会补充自建网页文本问题集，用来验证真实搜索环境下的效果。

对比方法：

对比方法包括四组。Direct LLM 不调用搜索工具，直接回答；Standard RAG 对原始问题进行单次检索；Agentic Search 允许多轮搜索，但不使用独立证据压缩；Ours 则加入检索触发、查询改写、网页证据压缩和预算控制。

收束：

通过这几组对比，可以观察从不检索、固定检索、多轮检索到优化检索的效果差异。

过渡：

评价时，我会从准确性、检索有效性、调用效率和稳定性几个方面衡量。

第 14 页：评价指标

这一页讲“怎么判断系统好不好”。

可以说：

评价指标主要分为五类。

逐项讲：

第一是答案准确性。对于有标准答案的数据集，使用 Exact Match 和 F1；对于自建问题，采用人工核验或基于证据的一致性评分。

第二是检索有效性，主要看支持答案的网页是否被命中、有效证据占比以及证据相关性。

第三是工具调用效率，统计平均搜索次数、平均读取网页数、响应时间、token 消耗和 API 费用。

第四是推理稳定性，对同一问题多次运行，比较答案一致性、证据一致性和失败率。

第五是可解释性，检查最终答案是否能对应明确证据来源，是否存在无证据断言。

收束：

这些指标可以同时反映回答质量和工具调用成本，符合本课题“质量与效率兼顾”的目标。

过渡：

最后介绍预期成果和风险应对。

第 15 页：预期成果与风险应对

这一页讲“最后交付什么”和“遇到问题怎么办”。

可以说：

预期成果主要包括四个方面。

成果：

第一，完成一个可运行的开放域问答工具调用智能体原型；第二，形成可复现实验脚本和评测数据集；第三，至少完成一种关键优化方法，并通过消融实验说明效果；第四，形成实验结果表、案例分析和毕业论文。

风险应对：

风险方面，搜索接口可能不稳定，所以会设置缓存、重试和备用接口；网页噪声较多，所以会通过长度、重复度和关键词覆盖率进行过滤；检索触发可能不稳定，所以采用规则信号、模型自评和预算限制；自建数据评价可能主观，所以会结合公开指标和人工核验表。

收束：

这些措施主要是保证系统可运行、实验可复现、结果可分析。

过渡：

最后一页对整个开题做一个总结。

第 16 页：总结

这一页把全篇收住，强调主线。

可以说：

总结来说，本课题面向开放域问答中的外部知识获取需求，设计一个可运行、可控制、可评测的网页检索工具调用智能体。

三点总结：

第一是系统实现，完成多轮检索与网页阅读流程；第二是链路优化，围绕检索触发、查询生成、网页证据整理和预算控制进行设计；第三是实验评测，从准确性、效率和稳定性三个方面验证系统效果。

最后一句：

本课题的核心不是单纯接入搜索工具，而是研究网页检索工具调用链路如何更稳定、更有效、更可控。

结束语：

我的汇报到此结束，请各位老师批评指正。

备用页建议

当前 `pre.tex` 中有几页被注释掉，可以作为备用内容：

- **模块设计**：老师问系统模块细节时使用。
- **进度安排**：老师问时间计划时使用。